arXiv:2506.08326v1 [cs.LG] 2025年6月10日

# 图学习模型的图提示:最新进展和未来方向

傅兴波
弗吉尼亚大学夏洛茨维尔，VA，USA
xf3av@virginia.edu

王泽宏
圣母大学圣母大学，IN，USA zwang43@nd.edu

陈子涵
USA弗吉尼亚州夏洛茨维尔市弗吉尼亚大学
brf3rx@virginia.edu

李佳政
康涅狄格大学
Storrs，CT，USA
jiazheng.li@uconn.edu

朱耀辰
弗吉尼亚大学夏洛茨维尔，VA，USA uqp4qh@virginia.edu

雷振宇
弗吉尼亚大学夏洛茨维尔，VA，USA
vjd5zr@virginia.edu

丛申
美国弗吉尼亚大学
夏洛茨维尔，弗吉尼亚州，USA
cong@virginia.edu

叶艳芳
巴黎圣母院
巴黎圣母院，IN，USA yye7@nd.edu

张楚旭
康涅狄格大学
Storrs, CT，USA chxu.zhang@uconn.edu

李俊东
USA弗吉尼亚州夏洛茨维尔市弗吉尼亚大学jundong@virginia.edu

图学习模型的提示:最新进展和未来方向。第31届ACM SIGKDD知识发现与数据挖掘会议论文集(KDD ' 25)， 2025年8月3-7日，加拿大多伦多。ACM，USA，纽约，11页。https://doi.org/10.1145/3711896.3736566

## 摘要

图学习模型在各种现实场景中从大规模图数据中学习表达表示方面表现出了巨大的能力。作为训练强大的图学习模型的一种流行策略，“预训练，自适应”方案首先以自监督的方式在未标记的图数据上预训练图学习模型，然后使其适应特定的下游任务。在自适应阶段，图提示作为一种很有前途的方法出现，它在保持预训练的图学习模型不变的同时学习可训练的提示。在本文中，我们对图提示的最新进展进行了系统回顾。首先，我们介绍了具有代表性的图预训练方法，作为图提示的基础步骤。接下来，我们回顾了图提示中的主流技术，并详细阐述了它们如何为图提示设计可学习的提示。此外，我们总结了来自不同领域的图提示在现实世界中的应用。最后，我们讨论了现有研究中的几个开放挑战，并展望了该领域的未来方向。

## CCS概念

· 计算方法学→机器学习; · 信息系统→数据挖掘。

## 关键词

图学习，图预训练，图提示

**ACM参考格式:**

傅兴波、王泽宏、陈子涵、李佳政、朱耀辰、雷振宇、沈聪、叶艳芳、张楚旭、李俊东。2025。曲线图

This work is licensed under a Creative Commons Attribution 4.0 International License. KDD ’ 25, Toronto, ON, Canada

©2025 Copyright held by the owner/author(s).
ACM ISBN 979-8-4007-1454-2/2025/08 https://doi.org/10.1145/3711896.3736566

## 1 简介

图在广泛的现实场景中很流行，例如生物信息学[111]、交通网络[75]和医疗保健系统[11]。为了从海量图数据中获得深入的见解，近年来已经开发了许多图学习模型，如图神经网络(gnn)[19,47,80,94,103]和图转换器[29,77,127]，并在不同的图相关下游任务中显示出巨大的能力，包括节点分类[62,135]，链接预测[34，141]，以及图分类[54,149]。传统上，图学习模型是通过监督学习来训练的。然而，监督式学习方式严重依赖于足够的标记图数据，这在现实世界中可能是不可行的。此外，训练好的图学习模型不能很好地推广到其他下游任务，即使是在相同的图数据上。这两个关键的限制阻碍了图学习模型的进一步实际部署。

为了克服上述限制，最近有许多研究研究了设计有效的预训练框架，以训练强大的图学习模型，而不使用来自下游任务的任何标签信息[23,24,30,95,106,107,109,118]。图预训练背后的理念是通过自监督学习学习表达性图表示来预训练图学习模型。通常，这些图表示嵌入了来自图数据的可泛化知识，可以用于下游任务。然而，预训练和下游任务之间存在着不可避免的客观差距。例如，一个图学习模型可以通过链接预测进行预训练，之后再适应节点分类作为下游任务。在这个例子中，我们对预训练期间用于链接预测的一对节点之间的关系更感兴趣，而作为下游任务的节点分类则更关注每个单个节点的表示。因此，图表示

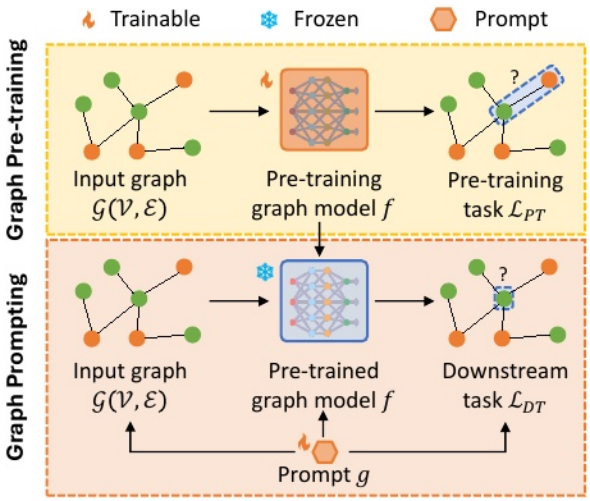


图1:图学习中“预训练、提示”方案的工作流程。

通过预训练的图学习模型学习，可能会对下游任务产生不利影响。

为了弥合客观差距，“预训练，提示”方案已被众多图学习研究广泛采用[9,12,59,84,86,124]。受自然语言处理[44,138]和计算机视觉[35,116]中最近的提示调优方法的启发，图提示通过学习额外的提示向量来适应预训练的图学习模型，同时保持预训练的图学习模型冻结。图1说明了“预训练、提示”方案的工作流程。与微调相比[31,136]，图形提示只需要更新更少的参数，使其更适合于few-shot设置。此外，图形提示更加灵活，因为可以为下游任务设计不同级别的可学习图形提示。这些优势使得图提示成为图学习中一个很有前途的话题，鼓励研究人员和实践者在学术界和工业界进一步探索其技术。

在本次调查中，我们对图提示背景下的现有文献进行了全面和最新的介绍。具体来说，我们首先介绍了具有代表性的图预训练方法，作为图提示的基础阶段。接下来，我们对图提示中的现有技术进行了有组织的总结。与之前的调查论文[61,87]相比，我们从图数据、节点表示和下游任务的角度提出了一种新的图提示方法分类。我们进一步介绍了图提示技术在各种现实世界领域的重要应用。最后，我们讨论了现有研究中的研究挑战和开放问题，旨在鼓励该领域的进一步发展。我们总结了我们调查论文的主要贡献如下。

- 新颖的分类学。我们的调查论文为现有的图预训练和提示方法提供了一种新的分类法，如图2所示。
- 最近的技术。与之前关于图形提示的调查论文相比，我们的调查论文中包含并介绍了更多最新的图形提示技术。
- 新方向。在现有技术的基础上，我们从不同的角度为图形提示的未来方向提供见解。

# 2 初步研究

## 2.1 注释和定义

首先，我们介绍图学习中的关键符号和定义。出于一般目的，我们在这篇调查论文中主要关注属性图。我们使用G = (V, E)来表示属性图，其中V ={V1，$_{V2}$，⋯，$_{VN}$}是$_{N}$nodes的集合，E∧V ×V是边集。也可以表示为G = (A, X)，这里，A∈{0，1}$^{N}$×Ndenotes其中的邻接矩阵$_{AIJ}$=1如果V，$_{VJ}$∈E，否则$_{AIJ}$=0。X∈R$^{N}$×$_{D^{x}}$denotes为特征矩阵，其中$^{I\text{-}th}$行$x_{I}$∈R$^{D_{x}}$is为节点$V_{I}$∈V的$^{D}$$_{X}$-dimensional特征向量。N($V_{I}$)表示节点$V_{I}$’s相邻节点的集合。

## 2.2 图学习模型

图学习模型是通过利用节点特征和图结构来学习图表示来建模图数据的强大工具。数学上，一个L-layer图学习模型F parameterized用θupdates的隐含表示矩阵H(L)∈RN×DLat的L-th层由

$$\mathbf{H}^{(l)} = f^{(l)}\left(\mathbf{A}, \mathbf{H}^{(l-1)}; \theta^{(l)}\right), \tag{1}$$

其中$_{\theta(L)}$表示$L_{\text{-}th}$层的参数。h($_{L)}$的$_{I\text{-}th}$行h(L)表示L-th层节点VIat的DL-dimensional隐藏表示，我们初始化h (0) = x。输出

节点的H ~(L)表示VIafter是图学习模型的最后一层，可用于不同的下游任务，如节点分类和图分类。

## 2.3 问题公式化

“预训练、提示”方案的目标是弥合预训练与下游任务之间的客观差距。为了实现这一目标，它首先以无监督的方式在预训练任务上训练图学习模型，然后使用可训练提示使预训练的图学习模型适应特定的下游任务，同时保持预训练的图学习模型冻结。更具体地说，通过预训练任务$L_{PT}$ via自监督学习训练的图学习模型Fis。在提示阶段，图提示训练可学习提示P使预训练的图学习模型Fto适应特定的下游任务$L_{DT}$。

# 3 图提示的图预训练

图预训练[105]通过利用未标记的数据来捕获图中的不变性，作为图提示的基础步骤。图预训练的核心目标是对图中的结构和语义一致性进行编码，从而增强其在下游任务中的效用。基于导出不变性所使用的机制，图预训练方法可以大致分为三类:生成法、对比法和多任务法。

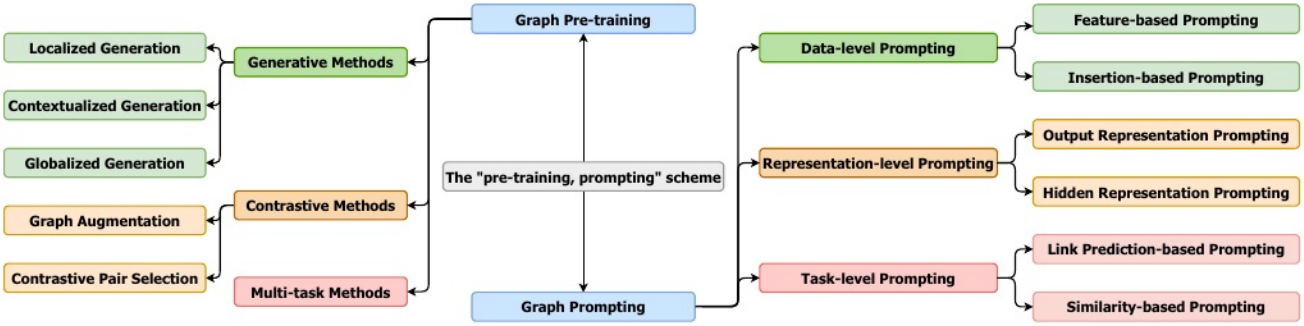


图2:“预训练、提示”方案中的技术分类。

## 3.1 生成方法

生成式预训练方法遵循去噪理念:故意破坏输入图的部分，训练模型以恢复丢失或改变的信息[24,46]。形式上，预训练任务$L_{PT}$can可以定义为

$$\min_{\theta} \ell(f(\tilde{\mathcal{G}};\theta), \rho(\mathcal{G})), \tag{2}$$

其中G≈= C(G)是由损坏函数C(·)产生的损坏图，ρ(·)表示创建重建目标的目标生成函数。损失函数r(·，·)测量损坏图表示与目标之间的差异。基于生成目标的粒度，现有的方法可以分为三个层次:本地化、语境化和全球化。

3.1.1局部生成。局部生成式预训练侧重于通过重构缺失节点属性或预测节点属性来学习细粒度的节点级信息。例如，GraphMAE[24]和随后的作品[23,53,89]采用了节点屏蔽，其中损坏函数从图G中移除节点V ′´V的子集，即C(G) = (A,XV′)), 目标生成函数旨在重构它们$\rho^{(G)}$ =XV′。或者，其他方法[27]屏蔽节点特征属性，即C(G) = (A, X)， ~，并训练模型预测其原始值ρ(G) = X。此外，几种方法旨在预测节点的内在属性，如中心性[30]和聚类系数[40]。在这些情况下，腐败可能是一个恒等函数C(G) = (A, X)(即没有腐败)，而ρ(G) =Pgenerates所需的统计度量P。

3.1.2情境化生成。情境化生成方法预测节点周围的结构信息，从而捕获局部邻域依赖关系。图自编码器(GAE)[46]通过破坏边缘并预测其原始连通性来重建图拓扑。在这里，C(G) = (A, ~ X)引入边缘移除或扰动，ρ(G) = A恢复缺失或改变的边缘。链接预测任务也作为某些图形提示设计的基本组成部分[59,84,122]。除了边缘预测，情境化生成已经扩展到捕获高阶结构。一些方法预测节点对之间的最短路径[72]，以保持远程依赖关系，而另一些方法则专注于识别与特定目标节点相关的子图motif[79]或语义聚类[83,120]。

3.1.3全球化一代。全球化生成方法通过保留整个图级属性来预训练图学习模型。在这些方法中，图通常保持不变;因此，腐败函数C(G) = (A, X)是恒等函数。图学习模型可以通过基于图相似度的目标进行预训练，其中由图学习模型生成的两个图的表示使用诸如图核相似度[67]、图编辑距离[45]、同构分数[50]或双曲距离[81]等指标进行比较。

## 3.2 对比方法

受对比学习在计算机视觉和NLP领域进展的启发，最近的研究将对比学习应用于图数据进行自监督图预训练。基本上，对比方法通过区分图数据中的相似和不相似实例来预训练图学习模型。首先，应用多个变换来生成不同的增强视图。更具体地说，给定一个图G = (A, X)，$_K$transformationsT1, T2，…，$T_K$通过。生成$_K$different增强视图

$$\tilde{\mathcal{G}}_k = (\mathbf{A}_k, \mathbf{X}_k) = \mathcal{T}_K(\mathbf{A}, \mathbf{X}), \ k = 1, 2, \cdots, K \tag{3}$$

$^K$graph学习模型(independent$_n$或权重共享)然后映射

(L)(L)(L)o

这些视图表示为$H_1$，$H_2$，⋯，$H_K$，其中(L)每个表示HK=F G ~K;eK。对比学习的目标是最大化正对之间的相似性，同时最小化负对之间的一致性

$$\max_{\{\theta_k\}_{k=1}^{K}} \sum_{i \neq j} s_{ij} \mathcal{I}(\mathbf{h}_i, \mathbf{h}_j), \quad \text{where } \mathcal{I}(\mathbf{h}_i, \mathbf{h}_j) = \mathbb{E}_{p(\mathbf{h}_i, \mathbf{h}_j)} \left[ \log \frac{p(\mathbf{h}_i, \mathbf{h}_j)}{p(\mathbf{h}_i) p(\mathbf{h}_j)} \right]. \tag{4}$$

这里，I(·，·)表示互信息(MI)，$S_{IJ}$∈{0，1}表示是否在$h_I$and$h_J$之间计算I。P(h，$h_J$))表示$h_I$and$h_J$的联合分布，P($h_I$)P($h_J$))表示边际积。由于MI是难以处理的，对比方法通常通过最小化来预训练图学习模型

对比损失，如InfoNCE[18]和Jensen-Shannon散度[68]。通常，对比方法包含图预训练的两个关键组成部分:图增强和对比对选择。

3.2.1图增强。图增强的目标是生成增广图，可以丰富或增强给定图数据中保留的信息。图增强中流行的一种技术是基于特征的增强。例如，节点特征掩蔽[27,39,40,92,119,147]随机选择一部分节点属性，并用常数或一些预定义的分布替换它们。类似地，节点特征洗牌[41,64,69,78,95]在一小部分节点之间切换特征。同时，许多研究通过对图拓扑的变换，采用了基于结构的增强方法。例如，边摄动[28,39,76,119,128,129,142]在G中随机添加或删除一部分边，而边扩散[13,21,43]通过结合全局拓扑信息，通过计算权值将节点与其间接连接的邻居连接起来，来增强a。此外，一些研究还使用基于抽样的增强方法，对G的子图用节点集V’V进行抽样。常见的抽样策略包括均匀抽样[128]、ego-net抽样[2、27、143]、随机游走抽样[21、76、119]和其他抽样[38、102、131]。

3.2.2对比配对选择。对比方法的第二个组成部分是选择合适的正对和负对。通常，对比对要么是同尺度的，要么是跨尺度的。在相同的粒度上选择相同的尺度对。例如，(子)图级方法[76、88、96、117、119、128]预训练图学习模型来预测两个(子)图是否来自同一来源，而节点级方法[17、20、33、74、91]将节点表示与其上下文邻域更紧密地对齐。现代方法[42、43、69、73、92、97、102、121、147、148]通过合并增广图的视图扩展了这一思想。相反，跨尺度对侧重于对图数据中的层次关系进行建模。例如，节点-(子)图方法[21,38,55,66,69,70,78,95,102,143]将节点表示与(子)图表示进行对比，旨在最大化它们之间的MI。这鼓励图学习模型同时捕获局部和全局语义。另一方面，子图-全局方法[2,82,85,99,131]从原始图或增广图中采样子图，并优化局部上下文表示和全局表示之间的MI。

## 3.3 多任务方法

除了流行的生成和对比方法之外，一些研究提出通过多任务学习来预训练图学习模型。例如，CPT-HG[37]为异构图上的gnn设计了一种对比预训练策略，该策略利用了关系级和子图级预训练任务。Hu等人[27]使用节点级任务(例如，上下文预测和属性屏蔽)和图级任务(例如，图属性预测和结构相似性预测)研究预训练gnn。MultiGPrompt[126]在预训练期间为多个预训练任务引入了一组借口令牌，这些令牌后来被用作组合提示以进行适应。

# 4 图提示中的技术

在本节中，我们将介绍图形提示中的现有技术。根据下游任务中的不同阶段，这些技术大致可以分为三类，即数据级提示、表示级提示和任务级提示。表1总结了不同类别下的图形提示技术。对于每个类别中的技术，我们将详细阐述它们的图提示的详细设计，以适应预训练的图学习模型。

## 4.1 数据级提示

受自然语言处理中流行的提示方法的启发[44,138]，一种简单的图提示策略是数据级提示。数据级提示背后的直觉是修改输入的图数据以适应特定的下游任务。具体来说，给定输入图G = (A, X)，数据级提示$T^D$learns将其转换为带有提示p的提示图G ~ = (A，≈X) ~正式地，我们可以通过

$$(\tilde{\mathbf{A}}, \tilde{\mathbf{X}}) = \mathcal{T}^D\left((\mathbf{A}, \mathbf{X}); \mathcal{P}\right). \tag{5}$$

值得注意的是，$T^D$may不会同时将P应用于A和X。根据修改的组件，数据级提示可以分为两种类型:基于特征的提示和基于插入的提示。

4.1.1基于特征的提示。我们首先通过单独修改特征矩阵来引入基于特征的提示。在这种情况下，图拓扑保持不变，即A ~ = A。基本上，基于特征的提示学习了一个额外的提示向量，该提示向量被添加到每个节点的特征向量中[9,36,48,51,56,65,123,140]。给定一个可学习的提示向量$p_I \in R^{D_x}$，节点$V_I$will有一个提示的特征向量$x\boxtimes_I=x_I+p_I$。这里的主要挑战是如何制定提示向量$p_I$。GPF[9]通过简单地学习所有节点的提示向量$p \in R^{D_x}$shared，即p1 = p2 =⋯=$p_N$=p，克服了这一挑战，其变体GPF-plus[9]进一步为每个节点分配了一个独立的提示向量。为了处理大规模的图，GPF-plus采用多个基向量的细心聚合来生成提示向量，使其参数效率更高，能够处理不同规模的图。更具体地说，给定一组$MD_X$-dimensional基向量b1, b2，⋯，$b_M$，我们计算每个节点的提示特征向量$V_I$by

$$\tilde{\mathbf{x}}_i = \mathbf{x}_i + \mathbf{p}_i = \mathbf{x}_i + \sum_{m=1}^{M} w_{i,m} \cdot \mathbf{b}_m, \tag{6}$$

其中每个$_{W,\ M}$是节点$V_I$的权重向量$w_I \in R^M$中的权重值。在GPF-plus中，$w_I$is计算为投影节点特征的softmax值$x_I$。其后续工作SUPT[48]计算$w_I$using由简单gnn得出的结果分数，而IAGPL[51]引入节点级实例感知图提示向量来获得$w_I$。它利用参数高效的骨干模型将特征空间转换为提示空间，从而使这些生成的提示是节点感知的。RELIEF[140]指出图形提示对于特定节点是必要的。RELIEF不是为每个节点学习提示向量，而是将插入提示的过程作为一个顺序决策问题来制定

表1:现有研究中图形提示技术的总结。单次前传是指图学习模型在图提示期间只执行一次向前。DT普适性意味着图形提示技术对于不同的下游任务是通用的，包括分类和回归。

| Technique Categories | Prompting Stage | Prompting Strategies | Single Forward Pass | DT Universality | Related Works |
|---|---|---|---|---|---|
| **Data-level prompting** | Graph data | Feature-based prompting | ✗ | ✓ | GPF-plus [9], IAGPL [51], GSPF [36], HetGPT [65], SUPT [48], DyGPrompt [123], FPrompt [56], RELIEF [140] |
| | | Insertion-based prompting | ✗ | ✓ | PSP [14], All-in-one [86], VNT [90], SGL-PT [144] |
| **Representation-level prompting** | Node representations | Output representation prompting | ✓ | ✓ | GraphPrompt [59], ProNoG [125] |
| | | Hidden representation prompting | ✗ | ✓ | EdgePrompt+ [12], GraphPrompt+ [122] |
| **Task-level prompting** | Downstream tasks | Link prediction-based prompting | ✓ | ✗ | GPPT [84] |
| | | Similarity-based prompting | ✓ | ✗ | ULTRA-DP [4], GraphPrompt [59], GraphPrompt+ [122], HetGPT [65], MultiGPrompt [126], ProNoG [125] |

并设计了一个强化学习框架来选择要提示的节点。GSPF[36]提出分配一个额外的可学习提示权值来调整提示向量对每个节点的影响。FPrompt[56]关注基于特性的提示的公平性问题。为了通过图形提示促进公平性，它提出将敏感性特征(sensitivity feature)纳入提示向量。

基于特征的提示也可以适用于其他类型的图形。例如，HetGPT[65]在异构图上推广了基于特征的提示。考虑到异构图中的多个节点类型，它为每个节点类型设计了具有特定基向量的类型加权向量。DyGPrompt[123]专注于基于特性的动态图形提示。它调查了预训练和下游任务之间的任务和动态差异所产生的差距。为了弥合差距，它采用双重条件网络[137]，分别从节点和时间的角度生成双重提示。

4.1.2基于插入的提示。基于插入的提示的直觉是将额外的提示节点作为可学习的提示插入到原始图中[14,86,90,144]。结果，原始图G被转换成提示图G ~，其中的节点包括提示节点和原始图的提示节点。在这种情况下，P中可学习的提示为Mprompt向量，即P = {p1, p2，⋯，$p_M$}。与基于特征的提示相比，这里的主要挑战在于将提示节点适当地整合到原始图中。SGL-PT[144]遵循图学习中的虚拟节点[25,26]的概念，将一个提示节点与原始图中的每个节点统一连接。类似地，PSP[14]设计了多个提示节点，这些节点统一连接到所有图节点。这些提示节点被视为分类任务的类原型。All-in-one[86]使用提示节点与原始图节点之间的点积定义插入模式。VNT[90]特别关注预训练图转换器的插入模式。与语言模型中的提示设计一样[137,139]，它将提示节点与图节点连接起来，并将其馈送到预训练的图转换器的变压器层。基于插入的提示的另一个挑战是确定如何适当地将提示节点彼此连接起来，特别是在插入多个提示节点时。All-in-one[86]通过提出三种方法解决了这一挑战:1)学习指示提示节点连接可能性的自由参数;2)计算每对提示节点的点积，并用预定义的阈值对其进行剪枝;3)将提示节点视为独立且不相连的。

虽然数据级提示对于各种下游任务是直接有效的，但它需要对每次更新执行预训练的图学习模型的整个向前和向后传递。与其他图形提示技术(例如，任务级提示)相比，它可能会导致训练图形提示和推理期间的时间延迟的显著计算成本。

## 4.2 表示级提示

除了学习修改输入图数据之外，另一个关键的图提示技术是表示级提示，它设计并应用可学习的提示到节点表示。在这里，节点表示可以指预训练的图学习模型的最后一层之后的输出表示或每一层的隐藏表示。具体来说，给定$L_{-th}$层的(隐藏的)表示矩阵H(L)，表示级提示$T^R$learns将其转换为带有提示p的提示表示矩阵H ~(L)，在数学上，我们可以制定表示级提示$T^R$by

$$\tilde{\mathbf{H}}^{(l)} = \mathcal{T}^R\left(\mathbf{H}^{(l)}; \mathcal{P}\right). \tag{7}$$

当提示仅应用于输出表示时，我们得到L=L。根据预训练图学习的层数

提示向量应用的模型，表示级提示方法可以分为输出表示提示和隐藏表示提示。

4.2.1输出表示提示。在输出表示提示中，提示向量在预训练的图学习模型的最后一层之后直接修改输出表示[59,125]。然后将修改后的表示用于下游任务。通常，输出表示提示方法使用一个可学习的提示向量$p_I \in R^{D_L}$for每个节点V<e:1>。数学-emtically，给定节点V的输出表示$h_I^{(L)}$，其修改后的表示h ~(L)是通过元素的方式获得的
乘以

$$\tilde{\mathbf{h}}_i^{(L)} = \mathbf{p}_i \odot \mathbf{h}_i^{(L)}, \tag{8}$$

其中⊙表示逐元素的乘法。提示向量$p_I$here作为维度明智的权重，为下游任务提取最相关的先验知识。直观上，Graph-Prompt[59]使用所有节点共享的通用提示向量，即$p1 = p2 = \cdots = p_N$。为了执行细粒度的自适应，ProNoG[125]训练了一个条件网络[137]，根据每个目标节点的多跳自我网络内节点的输出表示来生成节点明智的提示向量。这一策略对于异亲图尤其重要，因为节点的非同亲模式主要以其多跳邻域为特征。

4.2.2隐式表示提示。与将提示向量应用于输出表示的输出表示提示不同，隐藏表示提示方法为预训练的图学习模型设计分层提示[12,122]。例如，GraphPrompt+[122]通过修改预训练图学习模型每层的隐藏表示来增强GraphPrompt。因此，它将学习L+ 1个提示向量，每层分配一个提示向量，包括输入层。具体来说，修改后的隐藏表示是通过$\overline{h}$(L)(L)(L)= $\overline{p}$ ⊙$\overline{h}$来计算的。此外，EdgePrompt[12]提出在预训练的图学习模型的每一层为每条边学习一个共享提示向量。它的变体EdgePrompt+[12]通过学习customized每个边的提示向量扩展了边提示的思想。具体来说，给定每条边$V_I$，$V_J \in E$，其在L-th层的定制提示向量e(，L)J是基于隐含的(L)(L)计算的
表示节点$V_I$andVJ的$h_I$和$h_J$。然后，边缘提示$e_{I,J}$与节点的隐藏表示(L)一起聚合。
通过在预训练的图学习模型的每一层前向传递期间的消息传递机制。

与输出表示提示相比，隐藏表示提示通过分层提示向量进一步增强了自适应。然而，它需要在预训练的图学习模型的每一层进行隐藏表示，这可能不适用于黑箱图学习模型。相比之下，输出表示提示只需要预训练的图学习模型的最终输出，使其更灵活，计算效率更高。

## 4.3 任务级提示

在适应阶段，图形提示通常会遇到few-shot设置，即使用有限数量的标记图形数据来适应预训练的图形学习模型。解决这种情况的一个直接策略是使用传统的损失函数来训练线性探针[9,12,48]，例如分类任务的交叉熵损失和回归任务的均方误差。除了训练线性探针之外，许多研究探索将下游任务(特别是分类任务)重新表述为替代形式。我们将这种技术称为任务级提示。更具体地说，给定一个下游任务$L_{DT}$(e.g.，节点分类)，任务级提示$T^T$ transforms将其转化为不同的任务L⊠$_{DT}$for适配。值得注意的是，$T^T$may在某些情况下合并了额外的可学习提示P。在数学上，我们可以用

$$\tilde{\mathcal{L}}_{DT} = \mathcal{T}^T\left(\mathcal{L}_{DT}; \mathcal{P}\right). \tag{9}$$

一般来说，任务级提示方法大致可以分为两类:基于链接预测的提示和基于相似性的提示。

4.3.1基于链接预测的提示。当将链接预测用于预训练图学习模型，然后将其作为下游任务应用于节点分类时，就会出现客观差距。基于链接预测的提示[84]通过将节点分类转换为链接预测来弥补这一差距。因此，我们有L⊠$_{DT}$=$L_{PT}$。更具体地说，基于链接预测的提示使每个类C∈Y都有一个可学习的提示向量$s_C$。$s_C$is结合表示$h_I$ofa目标节点$V_I$作为链接预测预训练的投影头的输入。如果节点$V_I$’sground-truth标签$Y_I$=C，则投影头将节点$V_I$and类Cas视为“一对连接的节点”。因此，对提示向量进行调整，以预测$h_I$and$s_C$by投影头之间的最高链接概率。考虑到图数据的聚类结构，GPPT[84]提出为每个类学习聚类提示向量。虽然基于链接预测的提示非常直接，但它只兼容链接预测作为预训练任务，因为它需要通过链接预测预训练的投影头。此外，它只处理节点分类作为下游任务，不适用于其他任务，如节点回归和图分类。

4.3.2基于相似性的提示。基于相似性的提示不是使用交叉熵损失进行分类任务，而是使用对比损失将图表示与类原型进行比较[59,65,122,124,126]。更具体地说，给定训练集D中的一个实例-标签对(显性，显性)，其中$_X$is是一个可以是节点或图的实例，$_Y$∈Y是它来自一组类Y的基真类标签，基于相似性的提示旨在最大限度地提高显性表示$h_X$and与类原型$s_Y$of类<s:2>之间的相似性。形式上，我们将相似度任务L⊠$_{DT}$in相似度提示通过

$$\min_{\mathcal{P}} \sum_{(x,y)\in\mathcal{D}} -\log \frac{\exp\left(\operatorname{sim}\left(\mathbf{h}_x, \mathbf{s}_y\right)/\tau\right)}{\sum_{c\in\mathcal{Y}} \exp\left(\operatorname{sim}\left(\mathbf{h}_x, \mathbf{s}_c\right)/\tau\right)}, \tag{10}$$

其中sim(·，·)表示两个向量之间的相似性函数，τdenotes表示控制形状的温度超参数

的输出分布。为了获得类原型$s_C$，一些研究使用了属于类C的实例表示的平均值[59,122,124,126]。因此，在基于相似度的提示中没有引入额外的提示。与此同时，一些研究将类原型设计为可学习向量[4,65]。在这种情况下，类原型也包含在可学习提示符中。

虽然任务级提示方法可以通过将下游任务转换为其他任务(例如，从链接预测到节点分类)来有效地适应预训练的图学习模型，但它们的关键限制是它们只能处理分类任务。换句话说，当前的任务级提示方法在应用于分类以外的任务(如回归)时是无效的。

# 5 应用程序

图提示已经广泛应用于各个领域，包括推荐系统、知识工程、生物学和医学。在本节中，我们将介绍一些具有代表性的图提示在现实世界中的应用。

## 5.1 推荐系统

提示技术已广泛应用于基于语言模型的推荐系统中，以增强个性化和解释[15,58,145]。由于用户-物品交互自然形成二部图，因此基于gnn的推荐器(如Light-GCN[22])也得到了大量关注，可以引入图提示来进一步增强其自适应能力。例如，PGPRec[115]引入了特定于领域的节点提示，以使基于gnn的推荐器中的用户/项目嵌入适应于另一个领域，其中项目可能不同。GraphPro[113]通过使用相对交互时间预训练基于gnn的推荐器，并使用特定时间的边作为边提示来动态调整用户偏好，从而捕获用户不断变化的兴趣。CPTPP[112]使用交互矩阵来推断个性化提示，这些提示可以通过预训练的用户嵌入来增强推荐。GPT4Rec[130]通过引入交互图的多个隐藏视图，并利用节点和边缘提示来捕捉这些变化，对用户和项目的时间演变进行建模。最近，图形提示已被推广到基于图形语言模型的推荐系统，其中图形被转换为令牌序列，并丰富了针对不同下游任务定制的文本提示[108,146]。

## 5.2 Knowledge Engineering

另一个重要的应用是知识工程，现实世界的知识形成了知识图，而图提示有助于在不同的知识图和下游任务之间进行高效的信息检索，具有良好的泛化能力。KGTransformer[132]在采样子图上使用自监督学习预训练图学习模型，其中任务三元组作为提示符，在任务特定数据和KG表示之间实现灵活的交互。MUDOK[133]通过多域协同预训练和有效的前缀提示对KG模型进行预训练，其中任务三元组作为提示以增强应用间的可转移性。KG-ICL[6]使用基于提示的方法来构建特定于查询的提示图，通过利用上下文学习来执行通用关系推理而无需微调，从而使模型能够跨不同的知识图进行泛化。

## 5.3 生物与医学

图提示在生物学和医学领域也有应用，在这些领域，图结构数据很普遍，而标签却非常稀缺。一个关键的应用是分子图建模，其中原子表示为节点，键表示为边。给定预训练的分子图模型，MolCPT[7]可以从预测分子性质的分子基序中推断出连续的节点提示。MOAT[60]采用可适用于分子构象的几何级提示。TGPT[100]利用石墨烯及其频率来推断节点级、图级和任务级的图提示嵌入，这提高了图分子模型对各种分子拓扑结构的适应性。除了分子图之外，图提示也被应用于药物相互作用事件预测[104]，其中分子结构及其相互连接用于预训练图学习模型，而引入指示相互作用原型的可训练图提示以使模型适应不同的事件类型。此外，在医学成像应用中，MMGPL[71]利用MRI和PET数据来学习节点提示，这些节点提示可以与预训练的疾病概念图相结合，以提高诊断准确性。

# 6 未来发展方向

在本节中，我们提出了当前研究中的一些局限性，并为未来的进展提供了有希望的方向。

## 6.1 基准构建

尽管图形提示技术的有效性，现有的评估数据集面临几个关键的限制。首先，当前的图提示研究依赖于不同的数据集进行评估，这使得很难确保公平的比较。其次，经验评估是在不同的设置下进行的，包括射击次数、批量大小、学习率和其他因素的变化。第三，许多图提示方法没有使用足够的预训练策略进行评估，这使得它们的兼容性不明确。到目前为止，只引入了一个基准[150]来规范对图提示方法的评价。然而，图提示技术在更多设置下的性能仍未得到充分的探索。

## 6.2 理论基础

虽然图提示通过适应大型语言模型(法学硕士)的概念取得了经验上的成功[9,16]，但其理论基础仍然严重不发达。目前的方法缺乏对提示符为什么能够有效的知识转移或它们的结构如何与内在的图属性对齐的严格分析，这不仅限制了可解释性，而且还造成了性能瓶颈。一些作品已经对理论基础进行了早期的探索[10,32,101]。未来的工作可以通过建立基于图论的正式理论框架(例如谱图理论和几何深度学习)来进一步弥合这一差距，以系统地指导提示设计，解锁可解释和健壮的性能。

## 6.3 通用兼容性

与NLP提示不同，NLP提示受益于语言的结构一致性来指导法学硕士跨越不同的任务，现有的图提示是针对单个图和任务的特定特征量身定制的[59,84]。此外，对于具有更好表达能力的图形转换器的提示符设计的探索也很少[90]。因此，开发统一的图形提示框架将有助于适应不同的图形结构和任务，并且无需手动裁剪即可与图形转换器兼容。可能的方向包括利用可以自对齐图形属性(例如，规模和稀疏性)的动态提示体系结构。此外，集成跨域对齐机制[3,134]可以弥合不同图空间之间的差距，促进图提示的普遍适用性。

## 6.4 模型鲁棒性

图提示对对抗性攻击的鲁棒性研究尚不充分，现有方法缺乏对对抗性扰动的策略和严格分析，这是一个很有前景的研究方向。首先，图提示可以通过解决GNN上的结构扰动[98,151](例如节点注入和边缘修改)和基于特征的攻击[5,110](例如对抗性噪声)来增强GNN的鲁棒性。其次，图提示本身需要防御，因为当前以节点、边缘或特征为中心的提示设计有放大底层模型中的结构或特征漏洞的风险[57,63]。未来的工作可以优先考虑严格的对抗性测试，并整合防御机制，以确保对抗性设置中图提示的可靠性。

## 6.5 LLM incorporated

虽然图基础模型受到参数大小的限制[87]，限制了它们充分利用图提示的能力，但法学硕士通过出色的上下文推理能力提供了互补优势[1,49]。目前的方法弥补了这一差距，要么将图提示根植于语言空间以进行LLM处理[52,93,114]，要么使用法学硕士生成增强任务一致性的语义标签提示[8]。然而，更广泛的机会仍未被探索，例如利用法学硕士设计拓扑感知提示和提示优化，通过法学硕士的迭代反馈，这可以进一步增强法学硕士强大的上下文学习和推理能力的图形提示。

## 7 结语

在本调查中，我们对图学习模型的图提示的最新技术进行了全面的回顾。我们首先介绍了代表性的图预训练方法，作为图提示的基础阶段。然后，我们从图数据、节点表示和下游任务的角度深入研究图提示技术。此外，我们还介绍了图提示在各个领域的一些应用，包括推荐系统、知识工程、生物学和医学。最后，我们讨论了现有图提示研究的关键局限性及其未来可能的方向。

## 致谢

本工作得到美国国家科学基金会(NSF)的部分支持，资助项目为 IIS-2006844、IIS-2144209、IIS-2223769、CNS-2154962、BCS-2228534和CMMI-2411248;美国海军研究办公室(ONR)资助N000142412636;和联邦网络倡议(CCI)，授权VV-1Q24-011。

## 参考文献

[1] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. Advances in neural information processing systems 33 (2020), 1877–1901.

[2] Jiangxia Cao, Xixun Lin, Shu Guo, Luchen Liu, Tingwen Liu, and Bin Wang. 2021. Bipartite graph embedding via mutual information maximization. In Proceedings of the 14th ACM international conference on web search and data mining. 635–643.

[3] Liqun Chen, Zhe Gan, Yu Cheng, Linjie Li, Lawrence Carin, and Jingjing Liu. 2020. Graph optimal transport for cross-domain alignment. In International Conference on Machine Learning. PMLR, 1542–1553.

[4] Mouxiang Chen, Zemin Liu, Chenghao Liu, Jundong Li, Qiheng Mao, and Jian-ling Sun. 2023. Ultra-dp: Unifying graph pre-training with multi-task graph dual prompt. arXiv preprint arXiv:2310.14845 (2023).

[5] Yang Chen, Zhonglin Ye, Haixing Zhao, and Ying Wang. 2023. Feature-Based Graph Backdoor Attack in the Node Classification Task. International Journal of Intelligent Systems 2023, 1 (2023), 5418398.

[6] Yuanning Cui, Zequn Sun, and Wei Hu. 2024. A Prompt-Based Knowledge Graph Foundation Model for Universal In-Context Reasoning. NeurIPS 37 (2024), 7095–7124.

[7] Cameron Diao, Kaixiong Zhou, Zirui Liu, Xiao Huang, and Xia Hu. 2022. Molcpt: Molecule continuous prompt tuning to generalize molecular representation learning. arXiv preprint arXiv:2212.10614 (2022).

[8] Yutai Duan, Jie Liu, Shaowei Chen, Liyi Chen, and Jianhua Wu. 2024. G-Prompt: Graphon-based Prompt Tuning for graph classification. Information Processing & Management 61, 3 (2024), 103639.

[9] Taoran Fang, Yunchao Zhang, Yang Yang, Chunping Wang, and Lei Chen. 2023. Universal prompt tuning for graph neural networks. Advances in Neural Information Processing Systems (2023).

[10] Taoran Fang, Yunchao Zhang, Yang Yang, Chunping Wang, and Lei Chen. 2023. Universal prompt tuning for graph neural networks. Advances in Neural Information Processing Systems 36 (2023), 52464–52489.

[11] Xingbo Fu, Chen Chen, Yushun Dong, Anil Vullikanti, Eili Klein, Gregory Madden, and Jundong Li. 2023. Spatial-Temporal Networks for Antibiogram Pattern Prediction. In 2023 IEEE 11th International Conference on Healthcare Informatics (ICHI).

[12] Xingbo Fu, Yinhan He, and Jundong Li. 2025. Edge Prompt Tuning for Graph Neural Networks. In The Thirteenth International Conference on Learning Representations.

[13] Johannes Gasteiger, Stefan Weißenberger, and Stephan Günnemann. 2019. Diffusion improves graph learning. Advances in neural information processing systems (2019).

[14] Qingqing Ge, Zeyuan Zhao, Yiding Liu, Anfeng Cheng, Xiang Li, Shuaiqiang Wang, and Dawei Yin. 2024. PSP: Pre-training and Structure Prompt Tuning for Graph Neural Networks. In Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Springer, 423–439.

[15] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, and Yongfeng Zhang. 2022. Recommendation as language processing (RLP): A unified pretrain, personalized prompt & predict paradigm (P5). In RecSys. 299–315.

[16] Chenghua Gong, Xiang Li, Jianxiang Yu, Cheng Yao, Jiaqi Tan, Chengcheng Yu, and Dawei Yin. 2023. Prompt tuning for multi-view graph contrastive learning. arXiv preprint arXiv:2310.10362 (2023).

[17] Aditya Grover and Jure Leskovec. 2016. node2vec: Scalable feature learning for networks. In Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 855–864.

[18] Michael Gutmann and Aapo Hyvärinen. 2010. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. In Proceedings of the thirteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings, 297–304.

[19] Will Hamilton, Zhitao Ying, and Jure Leskovec. 2017. Inductive representation learning on large graphs. In Advances in neural information processing systems.

[20] Will Hamilton, Zhitao Ying, and Jure Leskovec. 2017. Inductive representation learning on large graphs. Advances in neural information processing systems 30 (2017).

[21] Kaveh Hassani and Amir Hosein Khasahmadi. 2020. Contrastive multi-view representation learning on graphs. In International conference on machine learning.

PMLR, 4116–4126.

[22] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and powering graph convolution network for recommendation. In SIGIR. 639–648.

[23] Zhenyu Hou, Yufei He, Yukuo Cen, Xiao Liu, Yuxiao Dong, Evgeny Kharlamov, and Jie Tang. 2023. Graphmae2: A decoding-enhanced masked self-supervised graph learner. In Proceedings of the ACM web conference 2023.

[24] Zhenyu Hou, Xiao Liu, Yukuo Cen, Yuxiao Dong, Hongxia Yang, Chunjie Wang, and Jie Tang. 2022. Graphmae: Self-supervised masked graph autoencoders. In Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[25] Weihua Hu, Matthias Fey, Hongyu Ren, Maho Nakata, Yuxiao Dong, and Jure Leskovec. 2021. Ogb-lsc: A large-scale challenge for machine learning on graphs. arXiv preprint arXiv:2103.09430 (2021).

[26] Weihua Hu, Matthias Fey, Marinka Zitnik, Yuxiao Dong, Hongyu Ren, Bowen Liu, Michele Catasta, and Jure Leskovec. 2020. Open graph benchmark: Datasets for machine learning on graphs. Advances in neural information processing systems (2020).

[27] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. 2020. Strategies for pre-training graph neural networks. In International Conference on Learning Representations.

[28] Ziniu Hu, Yuxiao Dong, Kuansan Wang, Kai-Wei Chang, and Yizhou Sun. 2020. Gpt-gnn: Generative pre-training of graph neural networks. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 1857–1867.

[29] Ziniu Hu, Yuxiao Dong, Kuansan Wang, and Yizhou Sun. 2020. Heterogeneous graph transformer. In Proceedings of the web conference 2020. 2704–2710.

[30] Ziniu Hu, Changjun Fan, Ting Chen, Kai-Wei Chang, and Yizhou Sun. 2019. Pre-training graph neural networks for generic structural feature extraction. arXiv preprint arXiv:1905.13728 (2019).

[31] Renhong Huang, Jiarong Xu, Xin Jiang, Chenglu Pan, Zhiming Yang, Chunping Wang, and Yang Yang. 2024. Measuring Task Similarity and Its Implication in Fine-Tuning Graph Neural Networks. In Proceedings of the AAAI Conference on Artificial Intelligence.

[32] Zhenhua Huang, Kunhao Li, Shaojie Wang, Zhaohong Jia, Wentao Zhu, and Sharad Mehrotra. 2024. Graph Structure Prompt Learning: A Novel Method-ology to Improve Performance of Graph Neural Networks. arXiv preprint arXiv:2407.11361 (2024).

[33] Dasol Hwang, Jinyoung Park, Sunyoung Kwon, KyungMin Kim, Jung-Woo Ha, and Hyunwoo J Kim. 2020. Self-supervised auxiliary learning with meta-paths for heterogeneous graphs. Advances in neural information processing systems 33 (2020), 10294–10305.

[34] EunJeong Hwang, Veronika Thost, Shib Sankar Dasgupta, and Tengfei Ma. 2022. An analysis of virtual nodes in graph neural networks for link prediction. In The First Learning on Graphs Conference.

[35] Menglin Jia, Luming Tang, Bor-Chun Chen, Claire Cardie, Serge Belongie, Bharath Hariharan, and Ser-Nam Lim. 2022. Visual prompt tuning. In European Conference on Computer Vision.

[36] Bo Jiang, Hao Wu, Ziyan Zhang, Beibei Wang, and Jin Tang. 2024. A unified graph selective prompt learning for graph neural networks. arXiv preprint arXiv:2406. 10498 (2024).

[37] Xunqiang Jiang, Yuanfu Lu, Yuan Fang, and Chuan Shi. 2021. Contrastive pre-training of GNNs on heterogeneous graphs. In Proceedings of the 30th ACM international conference on information & knowledge management.

[38] Yizhu Jiao, Yun Xiong, Jiawei Zhang, Yao Zhang, Tianqi Zhang, and Yangyong Zhu. 2020. Sub-graph contrast for scalable self-supervised graph representation learning. In 2020 IEEE international conference on data mining (ICDM). IEEE, 222–231.

[39] Ming Jin, Yizhen Zheng, Yuan-Fang Li, Chen Gong, Chuan Zhou, and Shirui Pan. 2021. Multi-scale contrastive siamese networks for self-supervised graph representation learning. In International Joint Conference on Artificial Intelligence 2021. Association for the Advancement of Artificial Intelligence (AAAI), 1477–1483.

[40] Wei Jin, Tyler Derr, Haochen Liu, Yiqi Wang, Suhang Wang, Zitao Liu, and Jiliang Tang. 2020. Self-supervised learning on graphs: Deep insights and new direction. arXiv preprint arXiv:2006.10141 (2020).

[41] Baoyu Jing, Chanyoung Park, and Hanghang Tong. 2021. Hdmi: High-order deep multiplex infomax. In Proceedings of the web conference 2021. 2414–2424.

[42] Nikola Jovanovi⊠, Zhao Meng, Lukas Faber, and Roger Wattenhofer. 2021. Towards robust graph contrastive learning. arXiv preprint arXiv:2102.13085 (2021).

[43] Zekarias T Kefato and Sarunas Girdzijauskas. 2021. Self-supervised graph neural networks without explicit negative sampling. arXiv preprint arXiv:2103. 14958 (2021).

[44] Muhammad Uzair Khattak, Hanoona Rasheed, Muhammad Maaz, Salman Khan, and Fahad Shahbaz Khan. 2023. Maple: Multi-modal prompt learning. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 19113–19122.

[45] Dongki Kim, Jinheon Baek, and Sung Ju Hwang. 2022. Graph self-supervised learning with accurate discrepancy learning. Advances in Neural Information Processing Systems (2022).

[46] Thomas N Kipf and Max Welling. 2016. Variational graph auto-encoders. arXiv preprint arXiv:1611.07308 (2016).

[47] Thomas N Kipf and Max Welling. 2017. Semi-supervised classification with graph convolutional networks. In International Conference on Learning Repre-sentations.

[48] Junhyun Lee, Wooseong Yang, and Jaewoo Kang. 2024. Subgraph-level universal prompt tuning. arXiv preprint arXiv:2402.10380 (2024).

[49] Brian Lester, Rami Al-Rfou, and Noah Constant. 2021. The power of scale for parameter-efficient prompt tuning. arXiv preprint arXiv:2104.08691 (2021).

[50] Jiangmeng Li, Yifan Jin, Hang Gao, Wenwen Qiang, Changwen Zheng, and Fuchun Sun. 2024. Hierarchical topology isomorphism expertise embedded graph contrastive learning. In Proceedings of the AAAI Conference on Artificial Intelligence.

[51] Jiazheng Li, Jundong Li, and Chuxu Zhang. 2025. Instance-Aware Graph Prompt Learning. Transactions on Machine Learning Research (2025).

[52] Jia Li, Xiangguo Sun, Yuhan Li, Zhixun Li, Hong Cheng, and Jeffrey Xu Yu. 2024. Graph intelligence with large language models and prompt learning. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 6545–6554.

[53] Jintang Li, Ruofan Wu, Wangbin Sun, Liang Chen, Sheng Tian, Liang Zhu, Changhua Meng, Zibin Zheng, and Weiqiang Wang. 2023. What' s behind the mask: Understanding masked graph modeling for graph autoencoders. In Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[54] Shuangli Li, Jingbo Zhou, Tong Xu, Dejing Dou, and Hui Xiong. 2022. Geomgcl: Geometric graph contrastive learning for molecular property prediction. In Proceedings of the AAAI conference on artificial intelligence.

[55] Xiang Li, Danhao Ding, Ben Kao, Yizhou Sun, and Nikos Mamoulis. 2021. Lever-aging meta-path contexts for classification in heterogeneous information net-works. In 2021 IEEE 37th International Conference on Data Engineering (ICDE). IEEE, 912–923.

[56] Zhengpin Li, Minhua Lin, Jian Wang, and Suhang Wang. 2025. Fairness-aware Prompt Tuning for Graph Neural Networks. In THE WEB CONFERENCE 2025.

[57] Minhua Lin, Zhiwei Zhang, Enyan Dai, Zongyu Wu, Yilong Wang, Xiang Zhang, and Suhang Wang. 2024. Trojan Prompt Attacks on Graph Neural Networks. arXiv preprint arXiv:2410.13974 (2024).

[58] Peng Liu, Lemei Zhang, and Jon Atle Gulla. 2023. Pre-train, prompt, and recom-mendation: A comprehensive survey of language modeling paradigm adapta-tions in recommender systems. TACL 11 (2023), 1553–1571.

[59] Zemin Liu, Xingtong Yu, Yuan Fang, and Xinming Zhang. 2023. Graphprompt: Unifying pre-training and downstream tasks for graph neural networks. In Proceedings of the ACM Web Conference 2023.

[60] Qingqing Long, Yuchen Yan, Wentao Cui, Wei Ju, Zhihong Zhu, Yuanchun Zhou, Xuezhi Wang, and Meng Xiao. 2024. MOAT: Graph prompting for 3D molecular graphs. In CIKM. 1586–1596.

[61] Qingqing Long, Yuchen Yan, Peiyan Zhang, Chen Fang, Wentao Cui, Zhiyuan Ning, Meng Xiao, Ning Cao, Xiao Luo, Lingjun Xu, et al. 2024. Towards Graph Prompt Learning: A Survey and Beyond. arXiv preprint arXiv:2408.14520 (2024).

[62] Sitao Luan, Chenqing Hua, Minkai Xu, Qincheng Lu, Jiaqi Zhu, Xiao-Wen Chang, Jie Fu, Jure Leskovec, and Doina Precup. 2023. When do graph neural networks help with node classification? investigating the homophily principle on node distinguishability. Advances in Neural Information Processing Systems (2023).

[63] Xiaoting Lyu, Yufei Han, Wei Wang, Hangwei Qian, Ivor Tsang, and Xiangliang Zhang. 2024. Cross-context backdoor attacks against graph prompt learning. In Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2094–2105.

[64] Kaili Ma, Haochen Yang, Han Yang, Yongqiang Chen, and James Cheng. 2021. Calibrating and improving graph contrastive learning. arXiv preprint arXiv:2101. 11525 (2021).

[65] Yihong Ma, Ning Yan, Jiayu Li, Masood Mortazavi, and Nitesh V Chawla. 2024. Hetgpt: Harnessing the power of prompt tuning in pre-trained heterogeneous graph neural networks. In Proceedings of the ACM on Web Conference 2024.

[66] Costas Mavromatis and George Karypis. 2020. Graph infoclust: Leveraging cluster-level node information for unsupervised graph representation learning. arXiv preprint arXiv:2009.06946 (2020).

[67] Nicolò Navarin, Dinh V Tran, and Alessandro Sperduti. 2018. Pre-training graph neural networks with kernels. arXiv preprint arXiv:1811.06930 (2018).

[68] Sebastian Nowozin, Botond Cseke, and Ryota Tomioka. 2016. f-gan: Training generative neural samplers using variational divergence minimization. Advances in neural information processing systems 29 (2016).

[69] Felix L Opolka, Aaron Solomon, Cătălina Cangea, Petar Veli⊠kovi⊠, Pietro Liò, and R Devon Hjelm. 2019. Spatio-temporal deep graph infomax. arXiv preprint arXiv:1904.06316 (2019).

[70] Chanyoung Park, Donghyun Kim, Jiawei Han, and Hwanjo Yu. 2020. Unsu-pervised attributed multiplex network embedding. In Proceedings of the AAAI conference on artificial intelligence, Vol. 34. 5371–5378.

[71] Liang Peng, Songyue Cai, Zongqian Wu, Huifang Shang, Xiaofeng Zhu, and Xiaoxiao Li. 2024. Mmgpl: Multimodal medical data analysis with graph prompt learning. Medical Image Analysis 97 (2024), 103225.

[72] Zhen Peng, Yixiang Dong, Minnan Luo, Xiao-Ming Wu, and Qinghua Zheng. 2020. Self-supervised graph representation learning via global context prediction. arXiv preprint arXiv:2003.01604 (2020).

[73] Zhen Peng, Wenbing Huang, Minnan Luo, Qinghua Zheng, Yu Rong, Tingyang Xu, and Junzhou Huang. 2020. Graph representation learning via graphical mutual information maximization. In Proceedings of The Web Conference 2020. 259–270.

[74] Bryan Perozzi, Rami Al-Rfou, and Steven Skiena. 2014. Deepwalk: Online learning of social representations. In Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 701–710.

[75] Jianzhong Qi, Zhuowei Zhao, Egemen Tanin, Tingru Cui, Neema Nassir, and Majid Sarvi. 2022. A graph and attentive multi-path convolutional network for traffic prediction. IEEE Transactions on Knowledge and Data Engineering (2022).

[76] Jiezhong Qiu, Qibin Chen, Yuxiao Dong, Jing Zhang, Hongxia Yang, Ming Ding, Kuansan Wang, and Jie Tang. 2020. Gcc: Graph contrastive coding for graph neural network pre-training. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 1150–1160.

[77] Ladislav Rampá☒ek, Michael Galkin, Vijay Prakash Dwivedi, Anh Tuan Luu, Guy Wolf, and Dominique Beaini. 2022. Recipe for a general, powerful, scalable graph transformer. Advances in Neural Information Processing Systems 35 (2022), 14501–14515.

[78] Yuxiang Ren, Bo Liu, Chao Huang, Peng Dai, Liefeng Bo, and Jiawei Zhang. 2019. Heterogeneous deep graph infomax. arXiv preprint arXiv:1911.08538 (2019).

[79] Yu Rong, Yatao Bian, Tingyang Xu, Weiyang Xie, Ying Wei, Wenbing Huang, and Junzhou Huang. 2020. Self-supervised graph transformer on large-scale molecular data. Advances in neural information processing systems (2020).

[80] Emanuele Rossi, Ben Chamberlain, Fabrizio Frasca, Davide Eynard, Federico Monti, and Michael Bronstein. 2020. Temporal graph networks for deep learning on dynamic graphs. arXiv preprint arXiv:2006.10637 (2020).

[81] Geri Skenderi, Hang Li, Jiliang Tang, and Marco Cristani. 2023. Graph-level representation learning with joint-embedding predictive architectures. arXiv preprint arXiv:2309.16014 (2023).

[82] Fan-Yun Sun, Jordan Hoffmann, Vikas Verma, and Jian Tang. 2020. Infograph: Unsupervised and semi-supervised graph-level representation learning via mutual information maximization. In International Conference on Learning Representations.

[83] Ke Sun, Zhouchen Lin, and Zhanxing Zhu. 2020. Multi-stage self-supervised learning for graph convolutional networks on graphs with few labeled nodes. In Proceedings of the AAAI conference on artificial intelligence.

[84] Mingchen Sun, Kaixiong Zhou, Xin He, Ying Wang, and Xin Wang. 2022. Gppt: Graph pre-training and prompt tuning to generalize graph neural networks. In Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[85] Qingyun Sun, Jianxin Li, Hao Peng, Jia Wu, Yuanxing Ning, Philip S Yu, and Lifang He. 2021. Sugar: Subgraph neural network with reinforcement pooling and self-supervised mutual information mechanism. In Proceedings of the web conference 2021. 2081–2091.

[86] Xiangguo Sun, Hong Cheng, Jia Li, Bo Liu, and Jihong Guan. 2023. All in one: Multi-task prompting for graph neural networks. In Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[87] Xiangguo Sun, Jiawen Zhang, Xixi Wu, Hong Cheng, Yun Xiong, and Jia Li. 2023. Graph prompt learning: A comprehensive survey and beyond. arXiv preprint arXiv: 2311.16534 (2023).

[88] Susheel Suresh, Pan Li, Cong Hao, and Jennifer Neville. 2021. Adversarial graph augmentation to improve graph contrastive learning. Advances in Neural Information Processing Systems 34 (2021), 15920–15933.

[89] Qiaoyu Tan, Ninghao Liu, Xiao Huang, Soo-Hyun Choi, Li Li, Rui Chen, and Xia Hu. 2023. S2gae: Self-supervised graph autoencoders are generalizable learners with graph masking. In Proceedings of the sixteenth ACM international conference on web search and data mining.

[90] Zhen Tan, Ruocheng Guo, Kaize Ding, and Huan Liu. 2023. Virtual node tun-ing for few-shot node classification. In Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[91] Jian Tang, Meng Qu, Mingzhe Wang, Ming Zhang, Jun Yan, and Qiaozhu Mei. 2015. Line: Large-scale information network embedding. In Proceedings of the 24th international conference on world wide web. 1067–1077.

[92] Shantanu Thakoor, Corentin Tallec, Mohammad Gheshlaghi Azar, Mehdi Az-abou, Eva L Dyer, Remi Munos, Petar Veli☒kovi☒, and Michal Valko. 2021. Large-scale representation learning on graphs via bootstrapping. arXiv preprint arXiv:2102. 06514 (2021).

[93] Yijun Tian, Huan Song, Zichen Wang, Haozhu Wang, Ziqing Hu, Fang Wang, Nitesh V Chawla, and Panpan Xu. 2024. Graph neural prompting with large language models. In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 38. 19080–19088.

[94] Petar Veli☒kovi☒, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lio, and Yoshua Bengio. 2018. Graph attention networks. In International Conference on Learning Representations.

[95] Petar Velickovic, William Fedus, William L Hamilton, Pietro Liò, Yoshua Bengio, and R Devon Hjelm. 2019. Deep graph infomax. ICLR (poster) 2, 3 (2019), 4.

[96] Vikas Verma, Thang Luong, Kenji Kawaguchi, Hieu Pham, and Quoc Le. 2021. Towards domain-agnostic contrastive learning. In International Conference on Machine Learning. PMLR, 10530–10541.

[97] Sheng Wan, Yibing Zhan, Liu Liu, Baosheng Yu, Shirui Pan, and Chen Gong. 2021. Contrastive graph poisson networks: Semi-supervised learning with extremely limited labels. Advances in Neural Information Processing Systems 34 (2021), 6316–6327.

[98] Binghui Wang, Jinyuan Jia, Xiaoyu Cao, and Neil Zhenqiang Gong. 2021. Cer-tified robustness of graph neural networks against adversarial structural per-turbation. In Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 1645–1653.

[99] Chenguang Wang and Ziwen Liu. 2021. Learning graph representation by aggregating subgraphs via mutual information maximization. arXiv preprint arXiv: 2103.13125 (2021).

[100] Jingchao Wang, Zhengnan Deng, Tongxu Lin, Wenyuan Li, and Shaobin Ling. 2024. A Novel Prompt Tuning for Graph Transformers: Tailoring Prompts to Graph Topologies. In KDD. 3116–3127.

[101] Qunzhong Wang, Xiangguo Sun, and Hong Cheng. 2024. Does Graph Prompt Work? A Data Operation Perspective with Theoretical Analysis. arXiv preprint arXiv: 2410.01635 (2024).

[102] Xiao Wang, Nian Liu, Hui Han, and Chuan Shi. 2021. Self-supervised heterogeneous graph neural network with co-contrastive learning. In Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 1726–1736.

[103] Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E Sarma, Michael M Bronstein, and Justin M Solomon. 2019. Dynamic graph cnn for learning on point clouds. ACM Transactions on Graphics (2019).

[104] Yingying Wang, Yun Xiong, Xixi Wu, Xiangguo Sun, Jiawei Zhang, and GuangY-ong Zheng. 2024. Ddiprompt: Drug-drug interaction event prediction based on graph prompt learning. In Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. 2431–2441.

[105] Zehong Wang, Zheyuan Liu, Tianyi Ma, Jiazheng Li, Zheyuan Zhang, Xingbo Fu, Yiyang Li, Zhengqing Yuan, Wei Song, Yijun Ma, et al. 2025. Graph Foundation Models: A Comprehensive Survey. arXiv preprint arXiv:2505.15116 (2025).

[106] Zehong Wang, Zheyuan Zhang, Nitesh V Chawla, Chuxu Zhang, and Yanfang Ye. 2024. GFT: Graph Foundation Model with Transferable Tree Vocabulary. In NeurIPS.

[107] Zehong Wang, Zheyuan Zhang, Tianyi Ma, Nitesh V Chawla, Chuxu Zhang, and Yanfang Ye. 2025. Towards Graph Foundation Models: Learning Generalities Across Graphs via Task-Trees. In ICML.

[108] Wei Wei, Xubin Ren, Jiabin Tang, Qinyong Wang, Lixin Su, Suqi Cheng, Junfeng Wang, Dawei Yin, and Chao Huang. 2024. Llmrec: Large language models with graph augmentation for recommendation. In Proceedings of the 17th ACM International Conference on Web Search and Data Mining. 806–815.

[109] Jun Xia, Lirong Wu, Jintao Chen, Bozhen Hu, and Stan Z Li. 2022. Simgrace: A simple framework for graph contrastive learning without data augmentation. In Proceedings of the ACM Web Conference 2022.

[110] Ying Xu, Michael Lanier, Anindya Sarkar, and Yevgeniy Vorobeychik. 2024. Attacks on node attributes in graph neural networks. arXiv preprint arXiv:2402.12426 (2024).

[111] Fang Yang, Kunjie Fan, Dandan Song, and Huakang Lin. 2020. Graph-based pre-diction of protein-protein interactions with attributed signed graph embedding. BMC bioinformatics (2020).

[112] Haoran Yang, Xiangyu Zhao, Yicong Li, Hongxu Chen, and Guandong Xu. 2023. An empirical study towards prompt-tuning for graph contrastive pre-training in recommendations. NeurIPS 36 (2023), 62853–62868.

[113] Yuhao Yang, Lianghao Xia, Da Luo, Kangyi Lin, and Chao Huang. 2024. Graph-pro: Graph pre-training and prompt learning for recommendation. In WWW. 3690–3699.

[114] Ruosong Ye, Caiqi Zhang, Runhui Wang, Shuyuan Xu, and Yongfeng Zhang. 2023. Language is all a graph needs. arXiv preprint arXiv:2308.07134 (2023).

[115] Zixuan Yi, Iadh Ounis, and Craig Macdonald. 2023. Contrastive graph prompt-tuning for cross-domain recommendation. ACM Transactions on Information Systems 42, 2 (2023), 1–28.

[116] Seungryong Yoo, Eunji Kim, Dahuin Jung, Jungbeom Lee, and Sungroh Yoon. 2023. Improving visual prompt tuning for self-supervised vision transformers. In International Conference on Machine Learning.

[117] Yuning You, Tianlong Chen, Yang Shen, and Zhangyang Wang. 2021. Graph contrastive learning automated. In International conference on machine learning. PMLR, 12121–12132.

[118] Yuning You, Tianlong Chen, Yongduo Sui, Ting Chen, Zhangyang Wang, and Yang Shen. 2020. Graph contrastive learning with augmentations. Advances in neural information processing systems (2020).

[119] Yuning You, Tianlong Chen, Yongduo Sui, Ting Chen, Zhangyang Wang, and Yang Shen. 2020. Graph contrastive learning with augmentations. Advances in

neural information processing systems 33 (2020), 5812–5823.

[120] Yuning You, Tianlong Chen, Zhangyang Wang, and Yang Shen. 2020. When does self-supervision help graph convolutional networks?. In international conference on machine learning.

[121] Junliang Yu, Hongzhi Yin, Min Gao, Xin Xia, Xiangliang Zhang, and Nguyen Quoc Viet Hung. 2021. Socially-aware self-supervised tri-training for recommendation. In Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2084–2092.

[122] Xingtong Yu, Zhenghao Liu, Yuan Fang, Zemin Liu, Sihong Chen, and Xinming Zhang. 2024. Generalized graph prompt: Toward a unification of pre-training and downstream tasks on graphs. IEEE Transactions on Knowledge and Data Engineering (2024).

[123] Xingtong Yu, Zhenghao Liu, Xinming Zhang, and Yuan Fang. 2025. Node-Time Conditional Prompt Learning in Dynamic Graphs. In The Thirteenth International Conference on Learning Representations. https://openreview. net/forum?id=kVlfYvIqaK

[124] Xingtong Yu, Jie Zhang, Yuan Fang, and Renhe Jiang. 2024. Non-homophilic graph pre-training and prompt learning. arXiv preprint arXiv:2408.12594 (2024).

[125] Xingtong Yu, Jie Zhang, Yuan Fang, and Renhe Jiang. 2025. Non-homophilic graph pre-training and prompt learning. In Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining.

[126] Xingtong Yu, Chang Zhou, Yuan Fang, and Xinming Zhang. 2024. MultiGPrompt for multi-task pre-training and prompting on graphs. In Proceedings of the ACM on Web Conference 2024.

[127] Seongjun Yun, Minbyul Jeong, Raehyun Kim, Jaewoo Kang, and Hyunwoo J Kim. 2019. Graph transformer networks. Advances in neural information processing systems 32 (2019).

[128] Jiaqi Zeng and Pengtao Xie. 2021. Contrastive self-supervised learning for graph classification. In Proceedings of the AAAI conference on Artificial Intelligence, Vol. 35. 10824–10832.

[129] Hanlin Zhang, Shuai Lin, Weiyang Liu, Pan Zhou, Jian Tang, Xiaodan Liang, and Eric P Xing. 2023. Iterative graph self-distillation. IEEE Transactions on Knowledge and Data Engineering 36, 3 (2023), 1161–1169.

[130] Peiyan Zhang, Yuchen Yan, Xi Zhang, Liying Kang, Chaozhuo Li, Feiran Huang, Senzhang Wang, and Sunghun Kim. 2024. Gpt4rec: Graph prompt tuning for streaming recommendation. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 1774–1784.

[131] Shichang Zhang, Ziniu Hu, Arjun Subramonian, and Yizhou Sun. 2024. Motif-driven contrastive learning of graph representations. IEEE Transactions on Knowledge and Data Engineering 36, 8 (2024), 4063–4075.

[132] Wen Zhang, Yushan Zhu, Mingyang Chen, Yuxia Geng, Yufeng Huang, Yajing Xu, Wenting Song, and Huajun Chen. 2023. Structure pretraining and prompt tuning for knowledge graph transfer. In WWW. 2581–2590.

[133] Yichi Zhang, Binbin Hu, Zhuo Chen, Lingbing Guo, Ziqi Liu, Zhiqiang Zhang, Lei Liang, Huajun Chen, and Wen Zhang. 2024. Multi-domain Knowledge Graph Collaborative Pre-training and Prompt Tuning for Diverse Downstream Tasks. arXiv preprint arXiv:2405.13085 (2024).

[134] Chuang Zhao, Hongke Zhao, Xiaomeng Li, Ming He, Jiahui Wang, and Jianping Fan. 2023. Cross-domain recommendation via progressive structural alignment. IEEE Transactions on Knowledge and Data Engineering 36, 6 (2023), 2401–2415.

[135] Tianxiang Zhao, Xiang Zhang, and Suhang Wang. 2024. Imbalanced node classification with synthetic over-sampling. IEEE Transactions on Knowledge and Data Engineering (2024).

[136] WANG Zhili, DI Shimin, CHEN Lei, and ZHOU Xiaofang. 2024. Search to fine-tune pre-trained graph neural networks for graph-level tasks. In 2024 IEEE 40th International Conference on Data Engineering (ICDE).

[137] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. 2022. Conditional prompt learning for vision-language models. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.

[138] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. 2022. Learning to prompt for vision-language models. International Journal of Computer Vision (2022).

[139] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. 2022. Learning to prompt for vision-language models. International Journal of Computer Vision (2022).

[140] Jiapeng Zhu, Zichen Ding, Jianxiang Yu, Jiaqi Tan, Xiang Li, and Weining Qian. 2024. Relief: Reinforcement learning empowered graph feature prompt tuning. arXiv preprint arXiv:2408.03195 (2024).

[141] Jing Zhu, Yuhang Zhou, Vassilis N Ioannidis, Shengyi Qian, Wei Ai, Xiang Song, and Danai Koutra. 2024. Pitfalls in link prediction with graph neural networks: Understanding the impact of target-link inclusion & better practices. In Proceedings of the 17th ACM International Conference on Web Search and Data Mining.

[142] Qikui Zhu, Bo Du, and Pingkun Yan. 2020. Self-supervised training of graph convolutional networks. arXiv preprint arXiv:2006.02380 (2020).

[143] Qi Zhu, Carl Yang, Yidan Xu, Haonan Wang, Chao Zhang, and Jiawei Han. 2021. Transfer learning of graph neural networks with ego-graph information maximization. Advances in Neural Information Processing Systems 34 (2021), 1766–1779.

[144] Yun Zhu, Jianhao Guo, and Siliang Tang. 2023. Sgl-pt: A strong graph learner with graph prompt tuning. arXiv preprint arXiv:2302.12449 (2023).

[145] Yaochen Zhu, Liang Wu, Qi Guo, Liangjie Hong, and Jundong Li. 2024. Collaborative large language model for recommender systems. In WWW. 3162–3172.

[146] Yaochen Zhu, Liang Wu, Binchi Zhang, Song Wang, Qi Guo, Liangjie Hong, Luke Simon, and Jundong Li. 2024. Understanding and Modeling Job Marketplace with Pretrained Language Models. In CIKM. 5143–5150.

[147] Yanqiao Zhu, Yichen Xu, Feng Yu, Qiang Liu, Shu Wu, and Liang Wang. 2020. Deep graph contrastive representation learning. arXiv preprint arXiv:2006. 04131 (2020).

[148] Yanqiao Zhu, Yichen Xu, Feng Yu, Qiang Liu, Shu Wu, and Liang Wang. 2021. Graph contrastive learning with adaptive augmentation. In Proceedings of the web conference 2021. 2069–2080.

[149] Xiang Zhuang, Qiang Zhang, Keyan Ding, Yatao Bian, Xiao Wang, Jingsong Lv, Hongyang Chen, and Huajun Chen. 2023. Learning invariant molecular representation in latent discrete space. Advances in Neural Information Processing Systems (2023).

[150] Chenyi Zi, Haihong Zhao, Xiangguo Sun, Yiqing Lin, Hong Cheng, and Jia Li. 2024. ProG: A Graph Prompt Learning Benchmark. arXiv preprint arXiv:2406. 05346 (2024).

[151] Daniel Zügner and Stephan Günnemann. 2020. Certifiable robustness of graph convolutional networks under structure perturbations. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 1656–1665.